GRADO EN CIENCIA E INGENIERÍA DE DATOS



Modelización Estadística de Datos de Alta Dimensión

En el archivo de datos vegetal.RData se guarda información sobre 24 parcelas correspondientes a sotobosques de pinos. Para cada parcela se tiene la siguiente información sobre el suelo:

- N, P, K, Ca, Mg, S, Al, Fe, Mn, Zn, Mo: contenido (en ppm) de los correspondientes elementos químicos.
- Baresoil: Cubierta de suelo desnudo (Low, High)
- Humdepth: grosor de la capa de humus (cm).
- pH: pH del suelo (Low, Med, High)

El objetivo es agrupar las parcelas, de modo que los grupos resultantes tengan una cierta homogeneidad. Para eso, responder las siguientes preguntas:

- Realizar un estudio descriptivo (univariante y multivariante) de las variables que se consideren de interés.
- 2. ¿Hay una única solución del problema?
- 3. ¿Variaría sustancialmente la solución si las variables se expresasen en otras unidades? ¿Cómo variaría, si es el caso?
- 4. ¿Cuántos grupos se deberían considerar? Razona la respuesta.
- 5. Agrupar las parcelas considerando un método jerárquico.
 - a) Representar gráficamente la solución obtenida.
 - b) Determinar qué parcelas pertenecen a cada grupo.
 - c) Calcular las medias de cada una de las variables dentro de cada grupo.
 - d) Calcular la distancia entre medias de los diferentes grupos.
- 6. Agrupar las parcelas considerando un método no jerárquico.
 - a) ¿Cuál sería un número óptimo de grupos? Razona la respuesta.
 - b) Determinar qué parcelas pertenecen a cada grupo.
 - c) Calcular las medias de cada una de las variables dentro de cada cluster.
- 7. Aplicar un método no jerárquico diferente al del apartado anterior.
- 8. Comparar la similitud de estas tres soluciones. A la vista de los resultados obtenidos, ¿se puede afirmar que este análisis ha resultado útil? Justificar la respuesta.